

路线 7: Learning-Guided Optimization / 神经网络辅助混合优化

这条路线回答一个很现实的问题：既然比赛给了 4 张 64GB GPU，我们能不能把量子优化和深度学习结合起来？

可以，但要放在正确位置上。

神经网络不是“直接吐出最优解”的保证器。更靠谱的做法是：让神经网络学习优化流程里的局部策略，然后把它接到 QUBO、退火、QAOA、constrained mixer 和 hybrid workflow 里。

先说结论

目前我们的体系已经很完整，但不是终点。

原来的六条路线覆盖了：

- 如何把问题变成 QUBO / Ising。
- 如何处理约束。
- 如何用退火采样。
- 如何用 QAOA。
- 如何用 constrained mixer 保持部分可行性。
- 如何用 hybrid 分解处理大规模 MILP / MIQP。

新增第七路线后，体系多了一层：

学习哪些变量重要、哪些变量该固定、从哪里开始搜索、怎么修复非法解、
↪ 怎么调量子/退火参数。

这层非常适合 GPU。

神经网络能学什么

Warm-start

给一个 QUBO 或 MILP，神经网络预测每个 binary variable 取 1 的概率。

例如：

```
x0: 0.91
x1: 0.08
x2: 0.62
x3: 0.49
```

高置信度变量可以作为初始解、固定变量或 QAOA 初态权重。

Variable fixing

如果模型非常确信 $x_0 = 1$ 、 $x_1 = 0$ ，可以先固定它们，把剩下不确定变量交给 QUBO 子问题。

这和 hybrid 路线天然相连：

```
relaxation / neural policy
-> fixed variables
-> smaller QUBO
-> SA / QAOA / constrained mixer
```

Branching

MILP solver 的 branch-and-bound 需要选择“先分裂哪个变量”。GNN 可以学习 branching score。

这不直接求解原问题，但能改变搜索树大小。

Repair policy

当候选解非法时，repair 要决定删哪个、换哪个、翻哪个 bit。

神经网络或强化学习可以学习：

```
当前 violation 状态 -> 下一步 repair action
```

Parameter scheduling

QAOA 的 γ/β 、SA 的温度表、constrained mixer 的初始态权重，都可以由学习模型给出初值或候选分布。

神经网络不能保证什么

它不能保证全局最优。

深度学习模型通常是启发式。它能利用训练分布里的结构，但如果赛题分布变化很大，它可能失效。

所以比赛方案里必须保留：

- exact solver 小规模验证。
- simulated annealing / greedy baseline。
- feasibility checker。
- repair。
- objective recomputation。
- benchmark gap。

神经网络负责“更快找到好解”，不是负责“证明这就是最优解”。

QUBO 怎么变成神经网络输入

QUBO 本身就是图：

- 节点：binary variables。
- 边：二次项 $q_{ij} x_i x_j$ 。
- 节点特征：线性项、度数、正负耦合和、约束来源。
- 边特征：coupler coefficient。

我们的代码现在提供：

```
QuboGraphFeatureExtractor
```

它会导出：

```
node_features  
edges  
labels
```

这就是后续训练 GNN 的数据接口。

训练标签从哪里来

小规模问题：

```
exact solver -> optimal bitstring
```

中规模问题：

```
SA / hybrid / repair -> best feasible incumbent
```

大规模问题：

```
classical solver time-limited incumbent  
multi-solver ensemble  
human-designed heuristic
```

标签不一定完美。我们要记录 label source 和 confidence。

4 张 64GB GPU 怎么用

第一阶段：批量生成训练数据。

跑很多 problem instances，记录 QUBO graph、约束图、solver 输出、repair trace。

第二阶段：训练 GNN warm-start policy。

输入 QUBO 图，输出每个变量取 1 的概率。

第三阶段：训练 repair / local search policy。

把修复过程看成强化学习：

state: 当前 bitstring + violation + objective

action: flip / swap / drop / add

reward: violation 降低 + objective 改善

第四阶段：和量子路线结合。

用学习模型给：

- QAOA 初始参数。
- QAOA warm-start state。
- constrained mixer 的 feasible initial state。
- 退火初始解。
- hybrid 子问题变量集合。

和量子算法的关系

这条路线不是量子算法的替代品，而是量子算法的助推器。

对量子退火：

学习生成初态 / 子问题 / penalty 配置 / repair 策略

对 QAOA：

学习 gamma/beta 初值、warm-start state、可行初态、参数迁移

对 constrained mixer：

学习 feasible initial state 和 transition graph 偏好

对 hybrid：

学习变量固定、子问题选择和 repair

更高级量子算法放在哪里

有更高级的 QAOA 变体：

- multi-angle QAOA。
- counterdiabatic QAOA。
- digitized-counterdiabatic QAOA。
- gradually changing unitaries。
- warm-start QAOA。
- R-QAOA。

但它们大多不是全新入口，而是路线 4 和路线 5 的增强。

我们当前最合理的升级路线是：

```
先补 Learning-Guided Optimization
再把 advanced QAOA variants 放进 P2/P3
```

因为学习驱动层能同时服务退火、QAOA、constrained mixer 和 hybrid。

代码里的 P0 版本

当前新增了一个轻量 backend：

```
LearningGuidedSamplerBackend
```

它做五件事：

1. 从 QUBO 提取图特征
2. 用 linear warm-start policy 给变量打分
3. 先生成 logical candidate，再自动填 slack / auxiliary bits
4. 结合变量固定计划生成候选 bitstring
5. 做局部翻转改进，再交给统一 postprocessor

这不是最终神经网络，但它把接口打通了。

后续可以把 LinearWarmStartPolicy 替换成 PyTorch/GNN 模型。

现在代码里还有两个接口专门服务后续 GPU 训练：

```
LearningGuidedDatasetBuilder
-> 把 OptimizationProblem 批量转成 QUBO graph JSONL
-> 小规模用 exact solver 打标签
-> 中规模可替换成 SA / hybrid incumbent 打伪标签
```

VariableFixingPlan

-> 从 policy 概率和置信度生成 fixed bits / free bits
-> fixed bits 可交给 hybrid fix-and-optimize
-> free bits 可继续交给 SA / QAOA / constrained mixer

也就是说，route 7 的 P0 代码已经不是一句“以后训练 GNN”，而是有真实数据出口和求解入口。

比赛时怎么讲

可以这样讲：

我们的系统不是只跑一个量子算法。

它先把问题转成统一的 QUBO/Ising 表示，再用约束层保证可行性。

求解层有 simulated annealing、QAOA、constrained mixer 和 hybrid decomposition。

在 GPU 可用时，我们再训练 learning-guided policy，为这些求解器提供 warm-start、

↪ 变量固定和 repair 策略。

这比“我们用深度学习直接求最优”稳很多，也更像真实工程系统。

共读任务

读完这份后，回答三个问题：

1. 为什么神经网络不应该直接承诺最优性？
2. 如果只允许你用 GPU 做一件事，你会训练 warm-start policy、repair policy，还是 QAOA 参数预测器？
3. 对一个大规模赛题，哪些变量适合固定，哪些变量应该留给 QUBO / QAOA 子问题？

能答清这三个问题，你就知道 GPU 和量子优化应该怎么接了。

延伸阅读

- [Bengio et al., ML for Combinatorial Optimization](#)
- [Nair et al., Neural Networks for MIP](#)
- [Darvariu et al., Graph RL for CO](#)
- [Liu et al., Automated GNN for CO](#)
- [Chandarana et al., Digitized-counterdiabatic QAOA](#)
- [Falla and Safro, Constrained Counterdiabatic QAOA](#)